Benchmark des modèles d'IA locaux

> **Choix retenu : ministral-3:8b** comme LLM (rédaction des réponses) et **bge-m3** comme modèle d'embeddings (recherche des passages). Les deux tournent en local sur un Mac via Ollama : aucune donnée ne sort de la machine.

1. Besoins du projet

L'assistant répond à des questions à partir de nos documents (RAG). Le modèle doit donc :

- **Bien maîtriser le français** : questions et réponses en français.
- **Rester fidèle aux documents** : répondre uniquement à partir des passages fournis, et dire « je ne sais pas » plutôt qu'inventer.
- **Produire des comparaisons structurées** entre produits.
- **Tourner sur un ordinateur portable** (Mac) assez vite pour une démonstration.

2. Modèles étudiés : points forts et points faibles

Présélection de modèles légers disponibles sur Ollama, compatibles avec un ordinateur portable.

Modèle	Taille (Ollama)	Points forts	Points faibles
qwen2.5:1.5b	~1 Go	Très léger et rapide. Modèle fourni dans l'exemple du cours.	Trop petit pour des synthèses et des comparaisons fiables.
qwen3.5:4b	3,3 à 4,0 Go	Récent, contexte de 256K, licence Apache 2.0. Bon rapport qualité / taille.	Modèle multilingue : français correct mais moins naturel qu'un modèle Mistral.
ministral-3:3b	~3 Go (6 Go de RAM)	Mistral (France) : bon français. Léger, adapté aux Mac de 8 Go.	Moins solide que le 8B sur le raisonnement et les synthèses.
ministral-3:8b	~6 Go (10 Go de RAM)	Mistral (France) : très bon français, suit bien les consignes. Bon équilibre qualité / vitesse sur un Mac de 16 Go.	Demande un Mac de 16 Go pour être confortable.
qwen3.5:9b	~6,6 Go	Plus puissant en raisonnement, bon multilingue.	Un peu plus lourd, français moins naturel que Mistral.
gemma4:e4b	~9,6 Go	Modèle Google récent, multimodal (texte + image).	Lourd pour un portable, sans avantage clair pour un RAG textuel.

3. Méthode de test

- Script **bench.py** : 11 questions-test sur le document de démonstration (story.txt).
- Pour chaque question, **les mêmes passages** sont retrouvés dans la base et envoyés au modèle : seul le LLM change, la comparaison est équitable.
- 9 questions avec réponse attendue, vérifiées par **mot-clé** (ex. « Éclair » pour le nom du cheval).
- 2 **questions pièges** (âge de Léo, nom de sa mère) dont la réponse n'est pas dans le document : le modèle doit dire qu'il ne sait pas. Elles sont vérifiées à la main.
- Mesures : temps de réponse moyen, vitesse de génération (tokens par seconde), temps de chargement.

4. Résultats mesurés

Modèle	Bonnes réponses (mots-clés)	Temps moyen	Vitesse	Chargement
ministral-3:8b	8 / 9	4,7 s	19,3 tokens/s	4,7 s
ministral-3:3b	6 / 9	2,7 s	16,6 tokens/s	3,1 s

5. Pourquoi nous avons hésité entre les deux Mistral

Après la présélection, nous avons gardé la famille **Mistral** pour la qualité de son français. Il restait à choisir la taille :

- **ministral-3:3b** : deux fois plus léger, il tournerait sur tous les ordinateurs de l'équipe, y compris ceux de 8 Go de RAM, et devrait répondre plus vite.
- **ministral-3:8b** : plus lourd, mais meilleur pour ce qui compte le plus chez nous : rester fidèle aux documents et produire des comparaisons structurées entre produits.

Nous avons d'abord mesuré le 8B. Il tourne de façon fluide sur notre Mac (3 à 5 secondes par réponse) avec 8 bonnes réponses sur 9 : la qualité passant avant la vitesse, nous l'avons retenu. Le 3B reste notre solution de repli pour les machines moins puissantes.

Critère	ministral-3:3b	ministral-3:8b
Mémoire nécessaire	~6 Go de RAM	~10 Go de RAM
Taille du fichier	~3 Go	~6 Go
Bonnes réponses	6 / 9 (mesuré)	8 / 9 (mesuré)
Temps moyen	2,7 s (mesuré)	3,1 à 4,7 s (mesuré)
Usage conseillé	Mac de 8 Go, solution de repli	Mac de 16 Go et plus : notre choix

6. Modèle d'embeddings : bge-m3

Le modèle d'embeddings transforme les textes en vecteurs pour retrouver les passages proches d'une question. L'exemple du cours utilisait **nomic-embed-text**, conçu principalement pour l'anglais. Nous l'avons remplacé par **bge-m3** :

- **Multilingue** : il prend en charge plus de 100 langues.
- **Notre base ne sera pas entièrement en français** : une partie des sources (rapports, fiches produits) peut être en anglais. bge-m3 est conçu pour la recherche multilingue et inter-langues : une question en français peut retrouver un passage en anglais.
- **Textes longs** : jusqu'à 8 192 tokens par passage.
- **Disponible sur Ollama**, léger (567M paramètres), il tourne en local comme le LLM.

7. Conclusion

> Nous retenons le duo **ministral-3:8b + bge-m3**. Le 8B répond correctement à 8 questions sur 9 en 3 à 5 secondes sur un portable, avec un français de bonne qualité. bge-m3 garantit une recherche fiable même si nos sources mélangent français et anglais. Prochaine étape : refaire le test sur un échantillon de vraies données produits.

Sources

- Ollama – bibliothèque bge-m3 : registry.ollama.ai/library/bge-m3
- Chen et al., *BGE M3-Embedding*, arXiv 2402.03216
- TinyWeights – Run Ministral 3 locally : tinyweights.dev/posts/run-ministral-3-locally
- PromptQuorum – Best Small LLM 2026 : promptquorum.com/local-llms/small-local-llm-models
- MayhemCode – Best Local LLMs for 4–8 GB VRAM (2026) : mayhemcode.com
- DEV Community – Gemma 4 avec Ollama : dev.to/purpledoubled